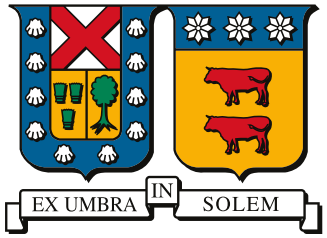

UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE MATEMÁTICA

Predicción de churn en clientes Telco: evaluación de cuatro enfoques de modelado

Aplicaciones de la matemática en la ingeniería (MAT281)

Integrantes:
Pablo Farias, Pablo Leiva, Benjamín Tondreau, Joaquin Inzunza, William Nuñez

2do semestre 2025

Contenidos

1. Acerca del problema
2. Objetivos
3. Descripción del dataset
4. Metodología
   - Modelo 1:
   - Modelo 2:
   - Modelo 3:
   - Modelo 4:
5. Resultados finales

DMAT
Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

¿Qué problema queremos resolver?

- La empresa pierde ingresos cuando un cliente se va.
- Retener clientes es menos costoso que conseguir nuevos clientes.
- Queremos predecir *churn*[1] antes de que ocurra.

[1] En este contexto, “churn” se refiere a la pérdida de un cliente, es decir, cuando da de baja el servicio o se cambia a otra compañía.

Objetivo del proyecto

- Construir 4 modelos de clasificación.
- Comparar su desempeño en la predicción de *churn*.
- Extraer conclusiones útiles para la empresa.

Dataset: Telco Customer Churn

- Cada fila del dataset es un cliente.
- El dataset cuenta con 7043 clientes.
- variable objetivo ***Churn*** (binaria: Sí o No).
- Variables:
  - Demográficas (género, pareja, dependientes).
  - Servicios contratados (internet, teléfono, TV, etc).
  - Facturación (meses en la compañia, cobro mensual, total pagado).

Dataset: Telco Customer Churn

Pequeña muestra del conjunto de datos con algunas columnas representativas

customerID	tenure	MonthlyCharges	Churn
7590-VHVEG	1	29.85	No
3668-QPYBK	2	53.85	Yes
9237-HQITU	2	70.70	Yes
1452-KIOVK	22	89.10	No

Desafíos del dataset

- Clases **desbalanceadas** (menos clientes que se van que los que se quedan).
- Algunas variables vienen como texto y hay que limpiarlas.
- Muchas variables categóricas (Sí/ No, tipo de contrato, tipo de internet, etc).

Flujo del trabajo

- Limpieza y preparación de datos.
- División en entrenamiento y prueba.
- Entrenamiento de 4 modelos.
- Evaluación en conjunto de prueba.
- Análisis de sobreajuste y métricas.

Preprocesamiento

- Eliminamos *CustomerID*.
- *TotalCharges* es variable numércia, se trataron espacios y vacíos.
- Escalamos numéricas (*tenure, MontlyCharges, TotalCharges*. con **StandardScaler** en regresión logística.
- Categóticas:
  - Algunas con **LabelEncoder** (binarias: Yes/No).
  - Otras con **one-hot encoding** (*get_dumies*) para Random Forest y XGBoost.

Modelos

1. Modelo 1: **Regresión Logística**: Modelo lienal, interpretable.
2. Modelo 2: **Random Forest**: Muchos árboles de desición, *class_weight='balanced'*.
3. Modelo 3: **XGBoost**: Ensamble de árboles (gradient boosting). Usa *scale_pos_weight* para el desbalance del **churn**.
4. Modelo 4: **Red neuronal**: perceptrón multicapa que combina las variables de forma no lineal y aprende pesos para aproximar la probabilidad de **churn**.

Regresión Logística

¿Qué hace?

- Asume relación lineal entre las variables log-odds de churn.
- devuelve una probabilidad de churn por cliente.
- Entrenado con *solver='liblinear'* y datos escalados.

Regresión Logística

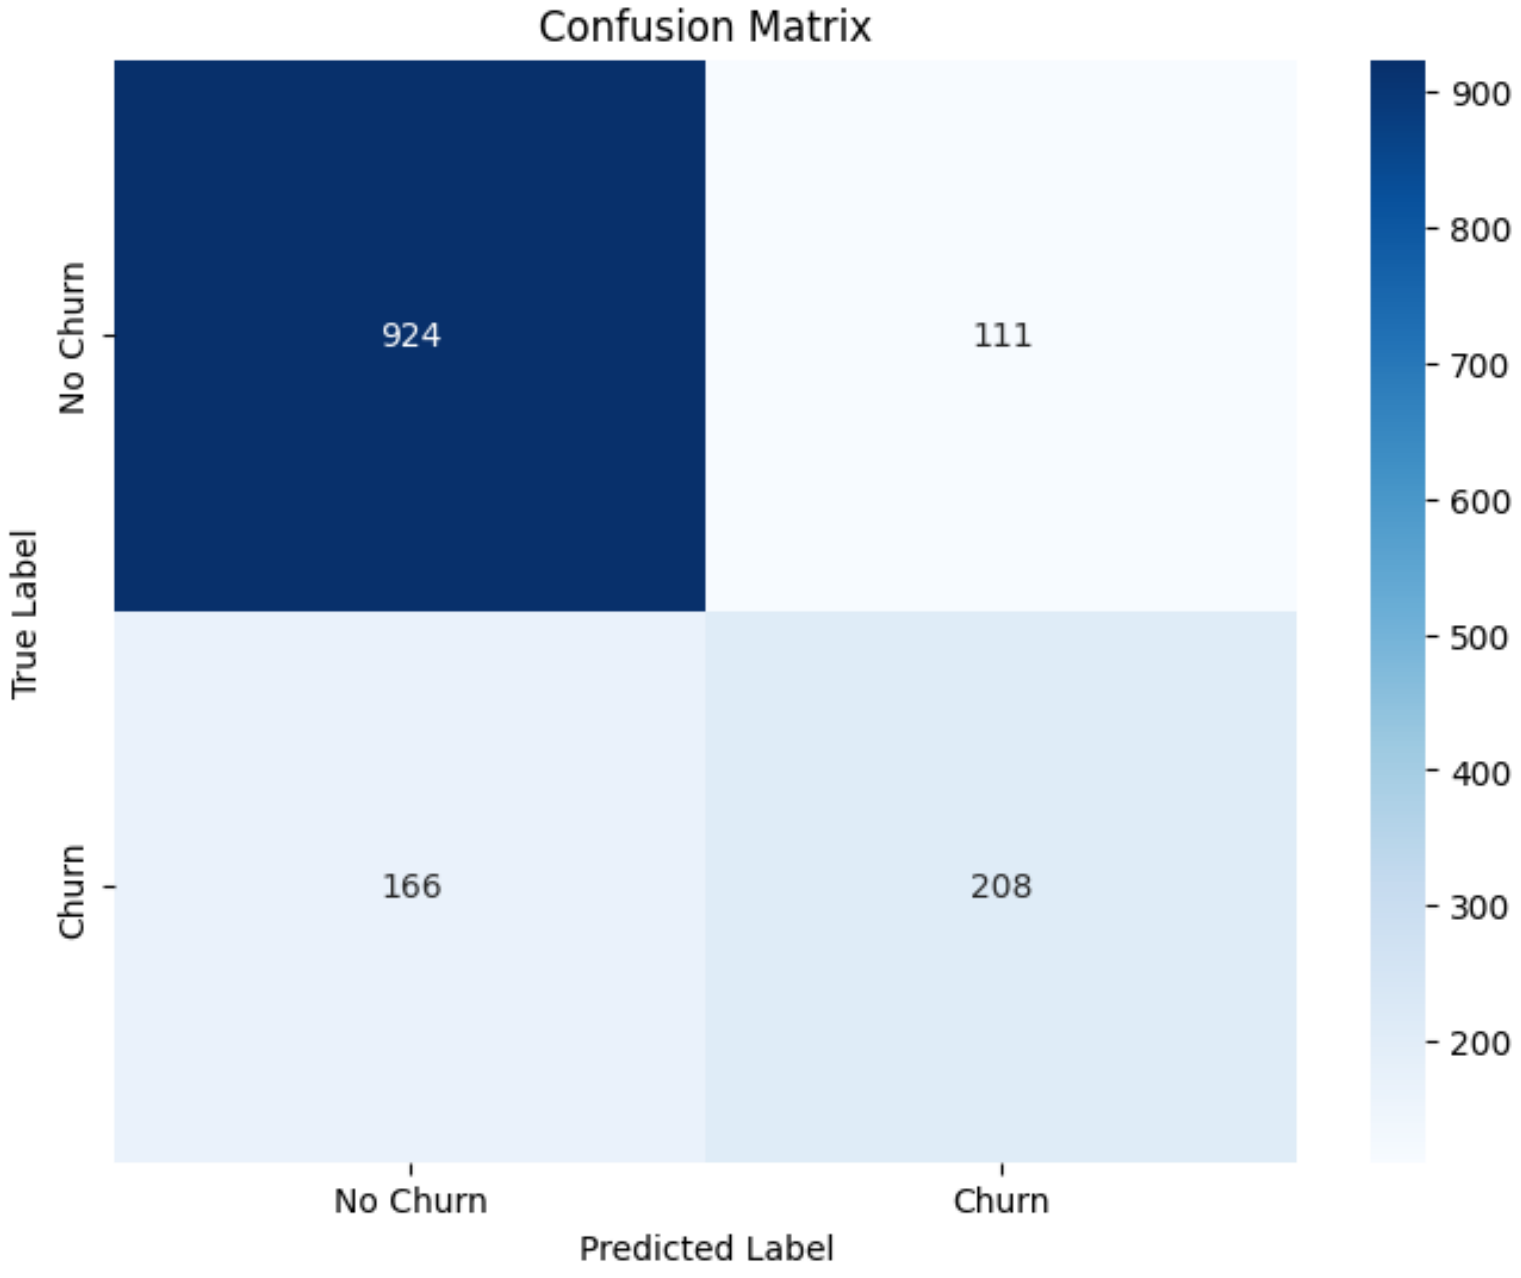

Regresión Logística

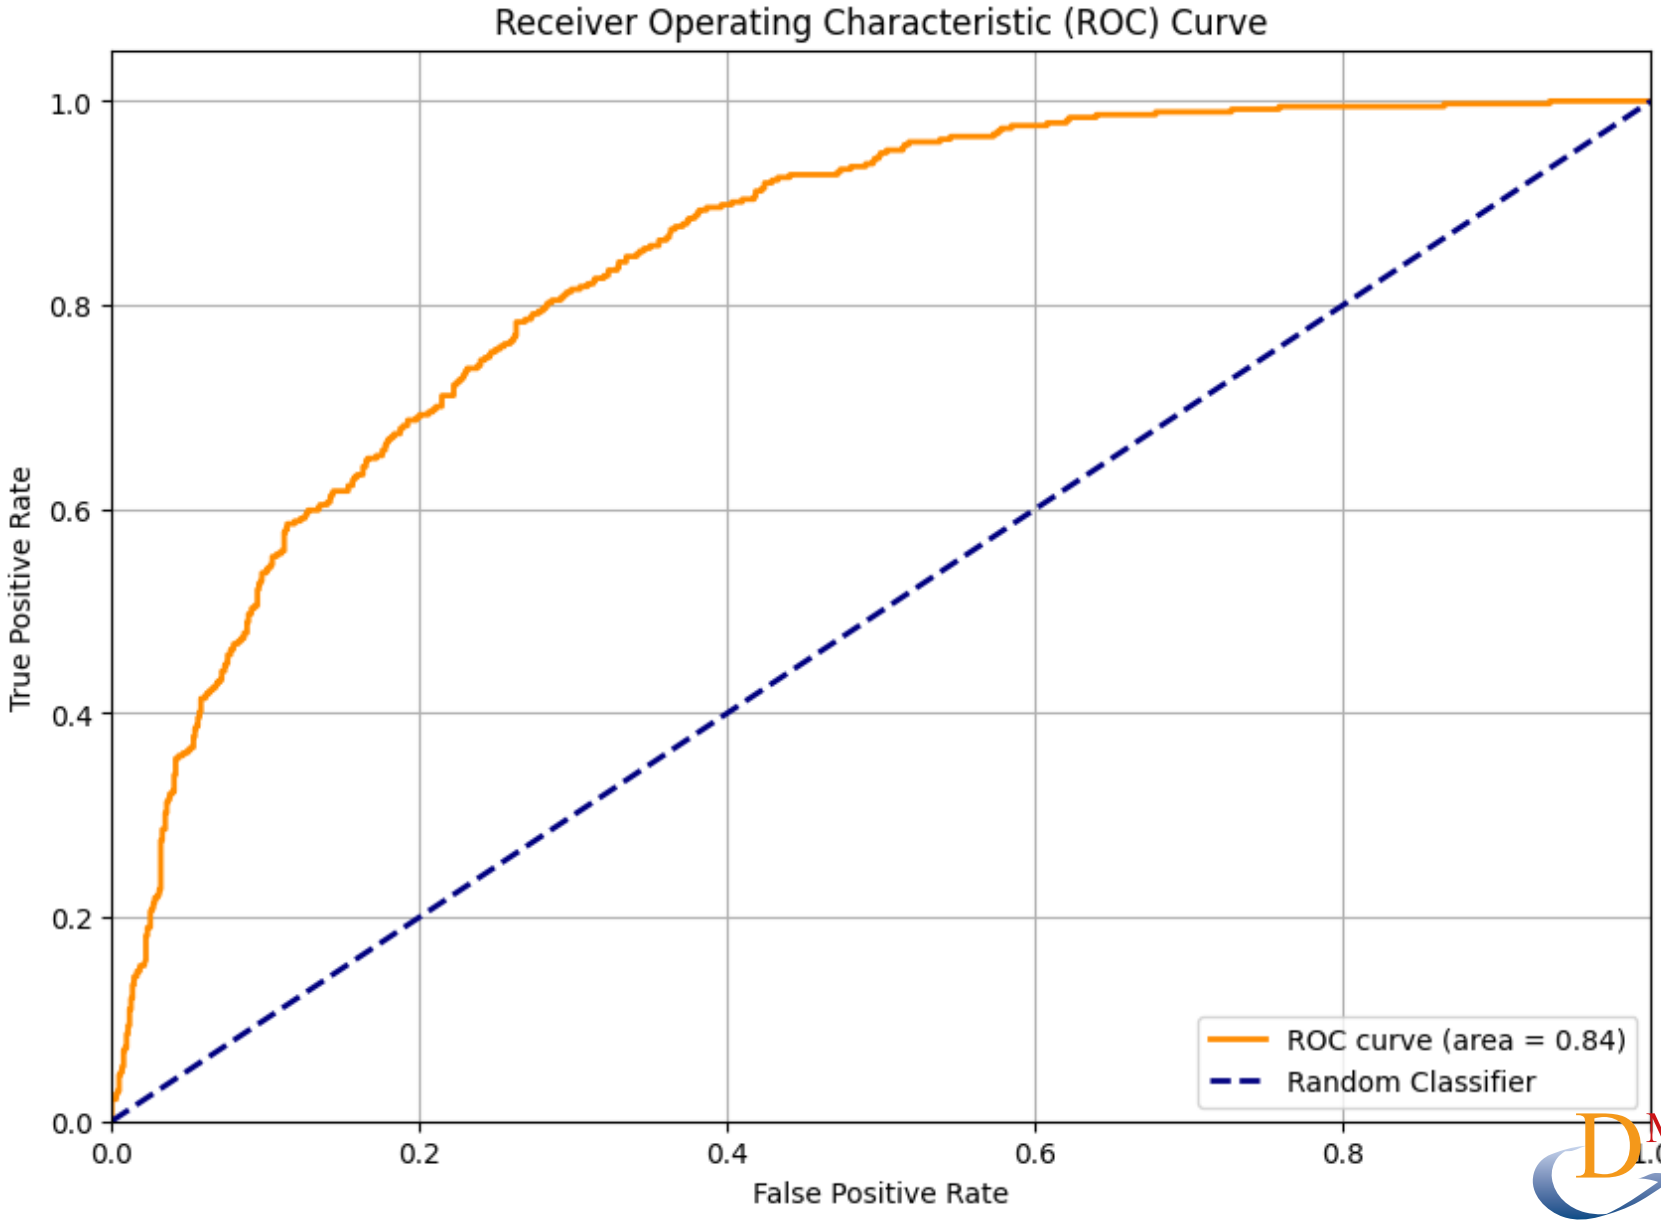

Regresión Logística

Resultados:

- Accuracy: 0.8034
- Precisión (churn): 0.6520
- Recall (churn):0.5561
- F1-score (churn): 0.6003
- ROC-AUC: 0.8422

Random Forest

¿Qué hace?

- Entrena **100 árboles** de desición.
- Cada árbol ve subconjuntos de variables y datos.
- Se usa *class_weight'balanced'* para compensar que hay menos churn que no-churn.

Random Forest

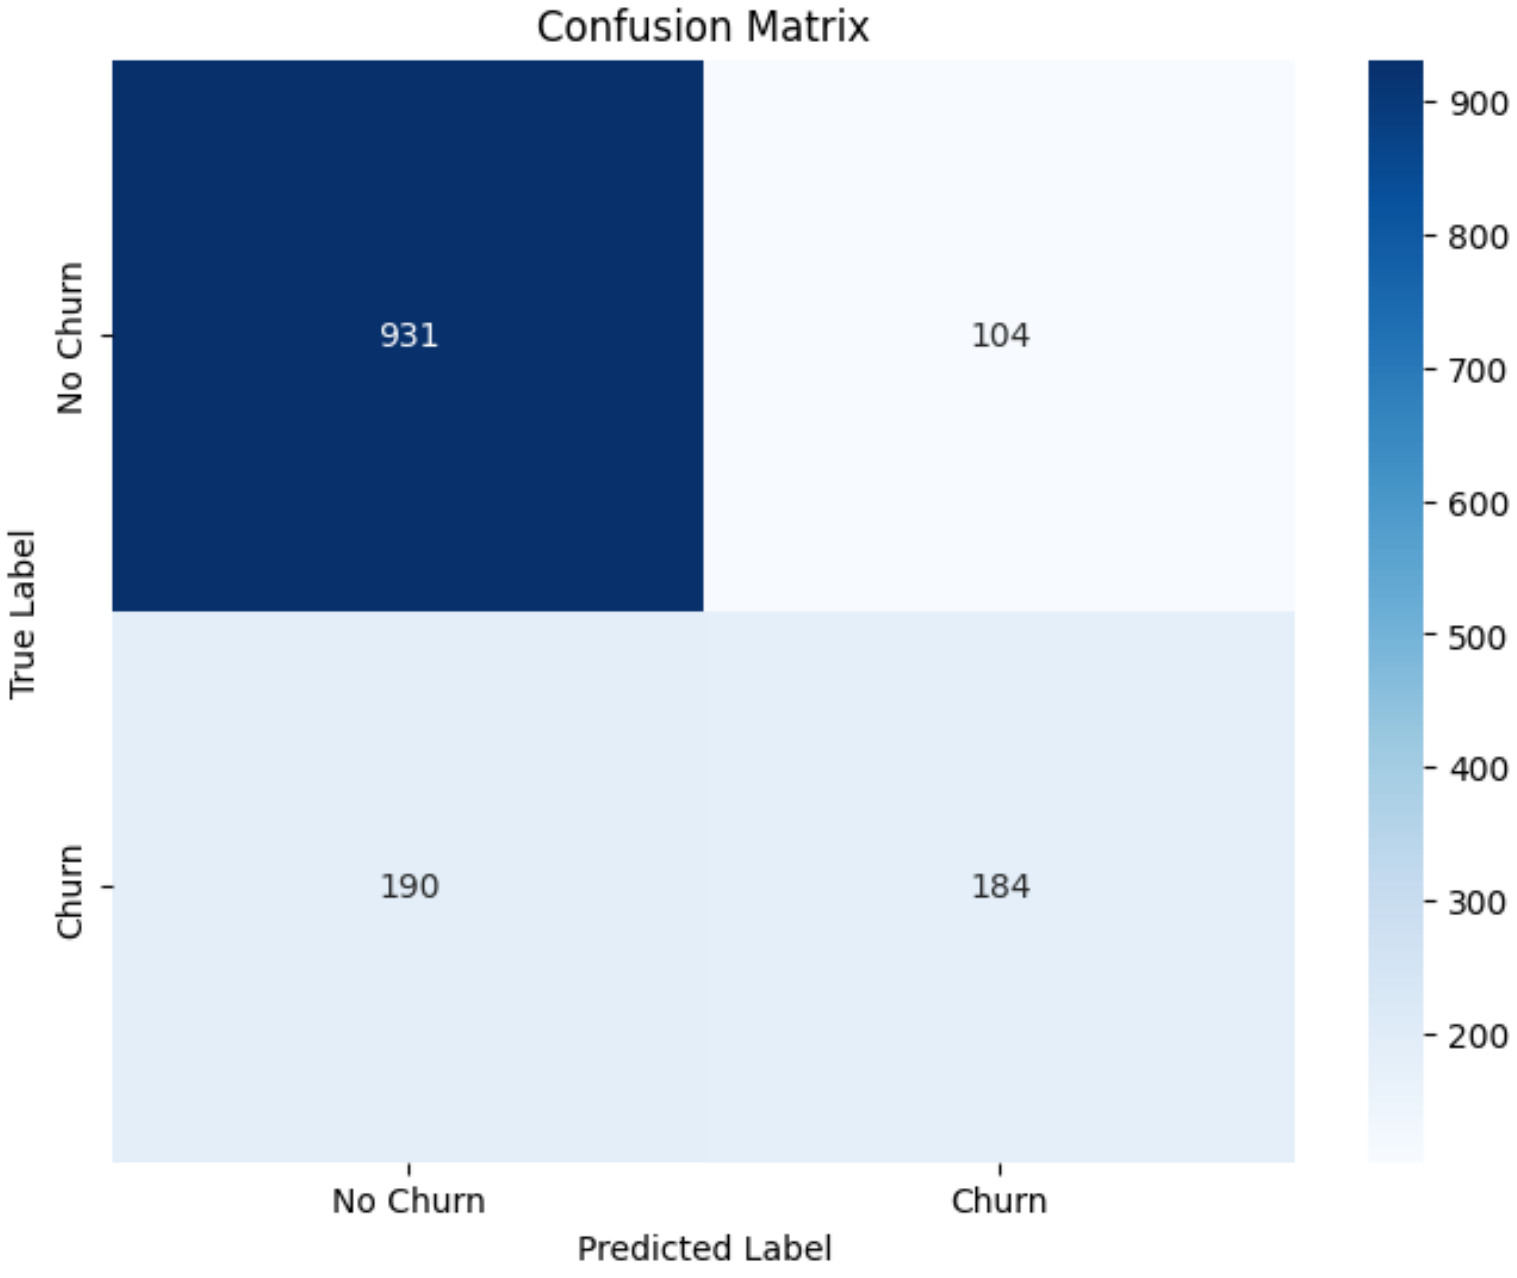

DMAT
Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Random Forest

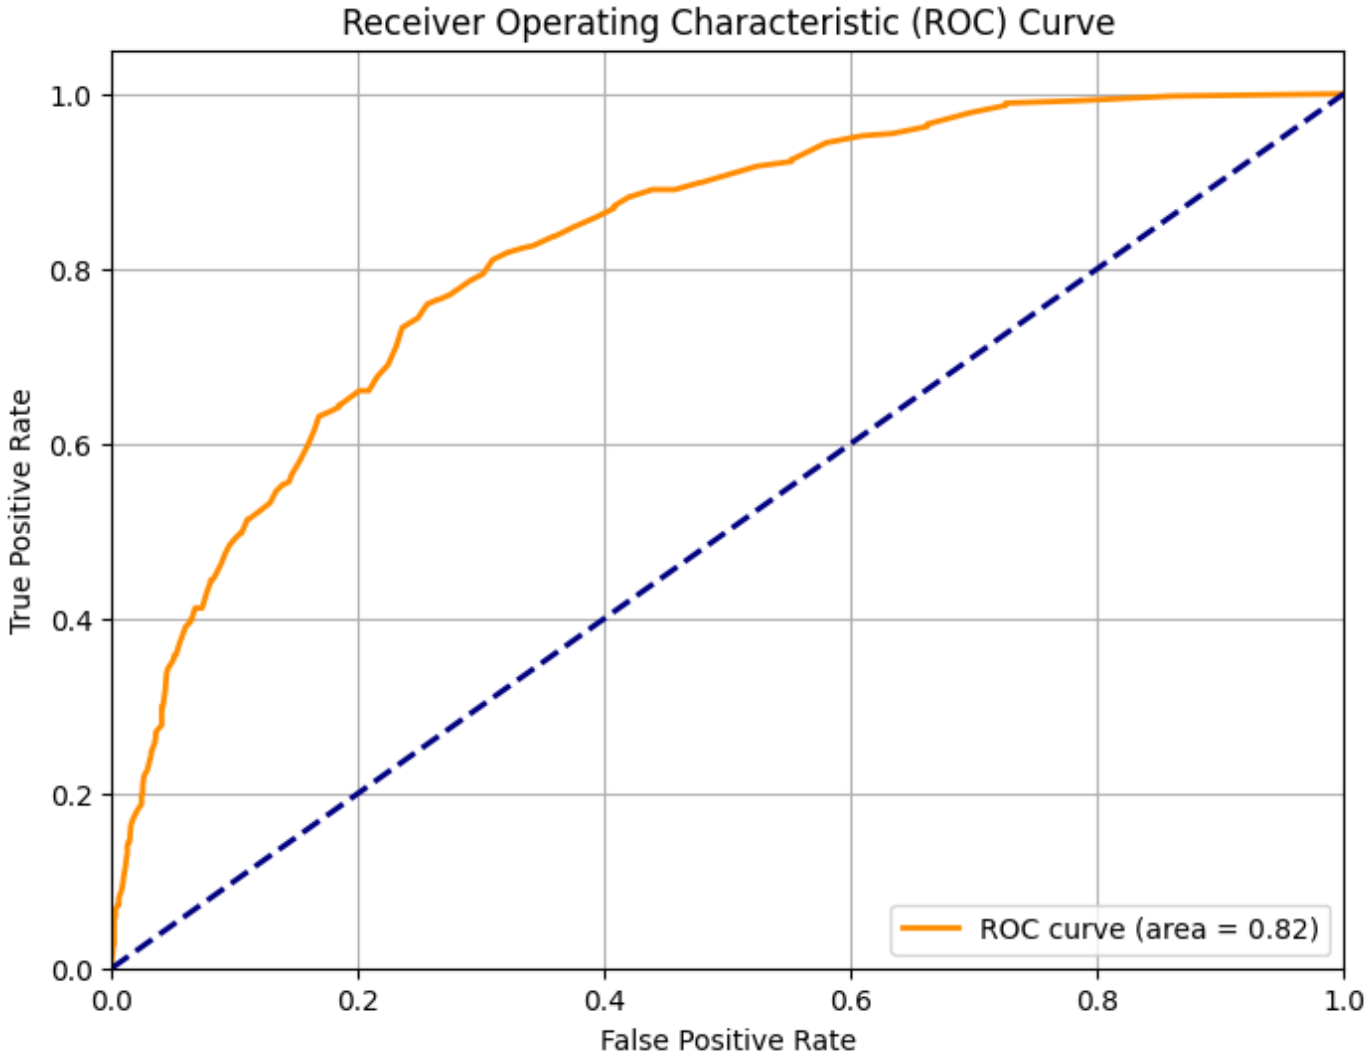

Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Random Forest

Resultados:

- Accuracy: 0.7913
- Clase 1 (churn):
  - Presición: 0.64
  - Recall: 0.49
  - F1: 0.56
- ROC-AUC: 0.8224

XGBoost

¿Qué hace?

- Es un modelo de aprendizaje automático basado en árboles de decisión.
- Construye muchos árboles pequeños de forma secuencial.
- Cada nuevo árbol se entrena para corregir los errores de los árboles anteriores.
- La predicción final es la suma de las contribuciones de todos los árboles.
- Utiliza una tasa de aprendizaje y regularización para evitar el sobreajuste.
- Es especialmente eficaz en datos tabulares y captura relaciones no lineales e interacciones entre variables.

XGBoost

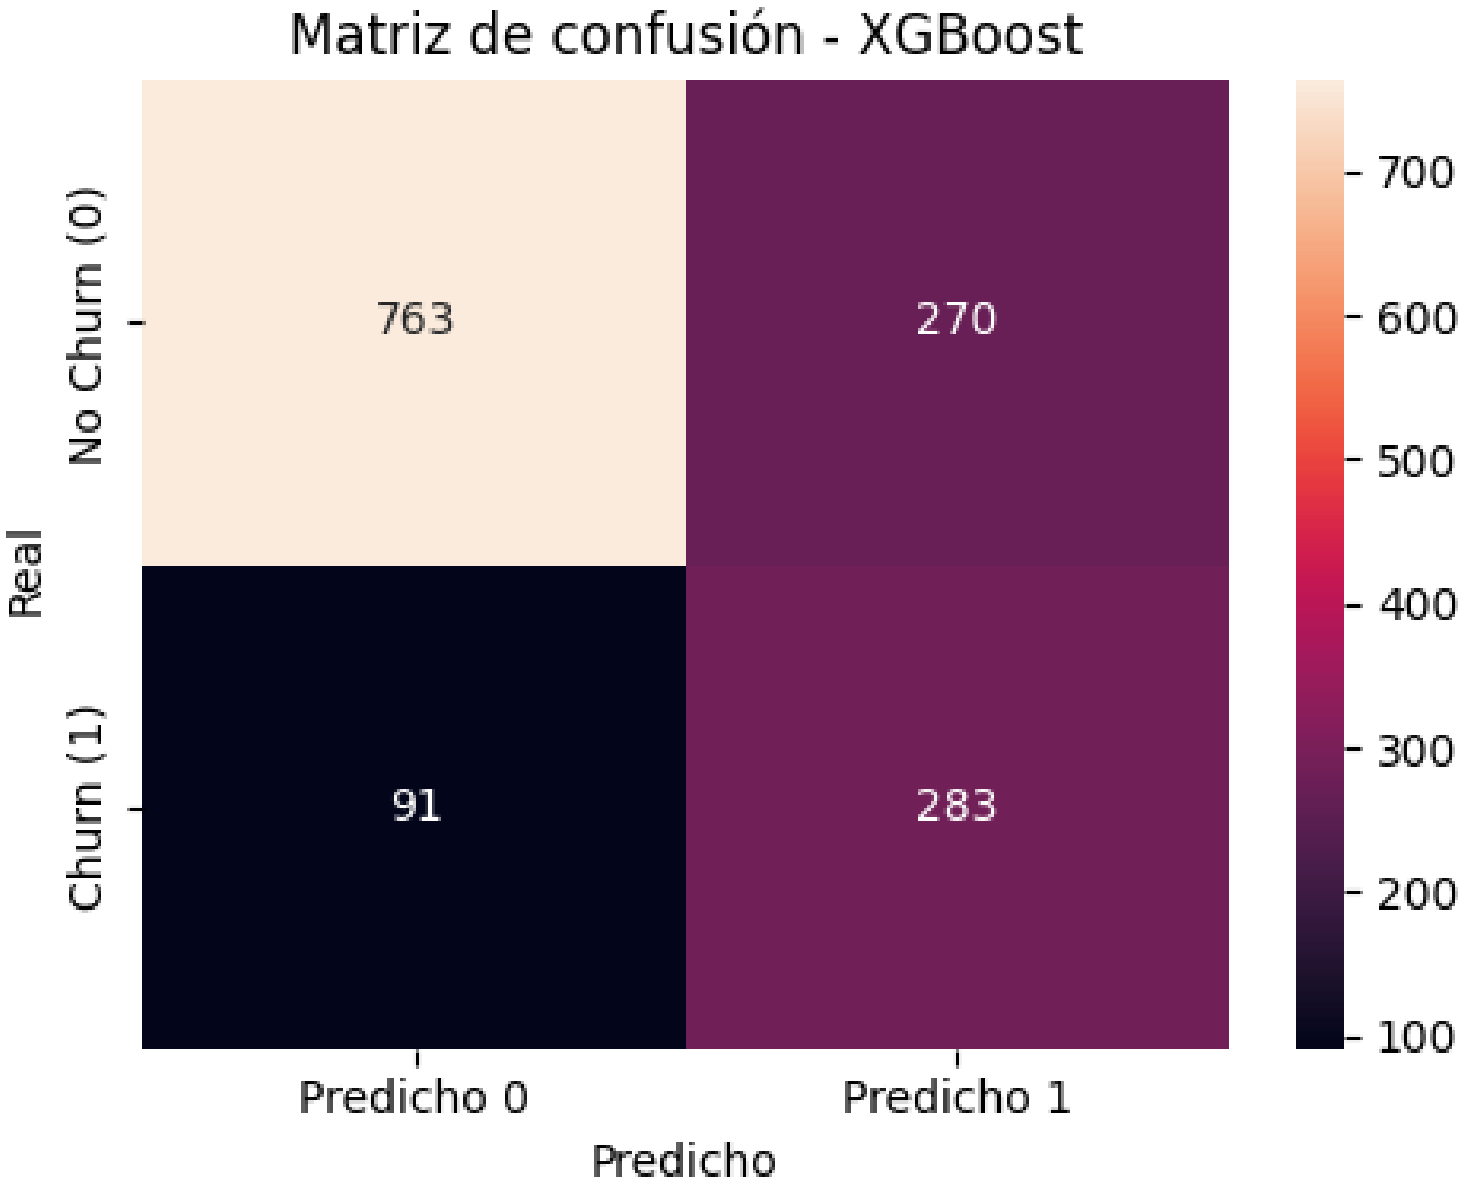

DMAT
Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

XGBoost

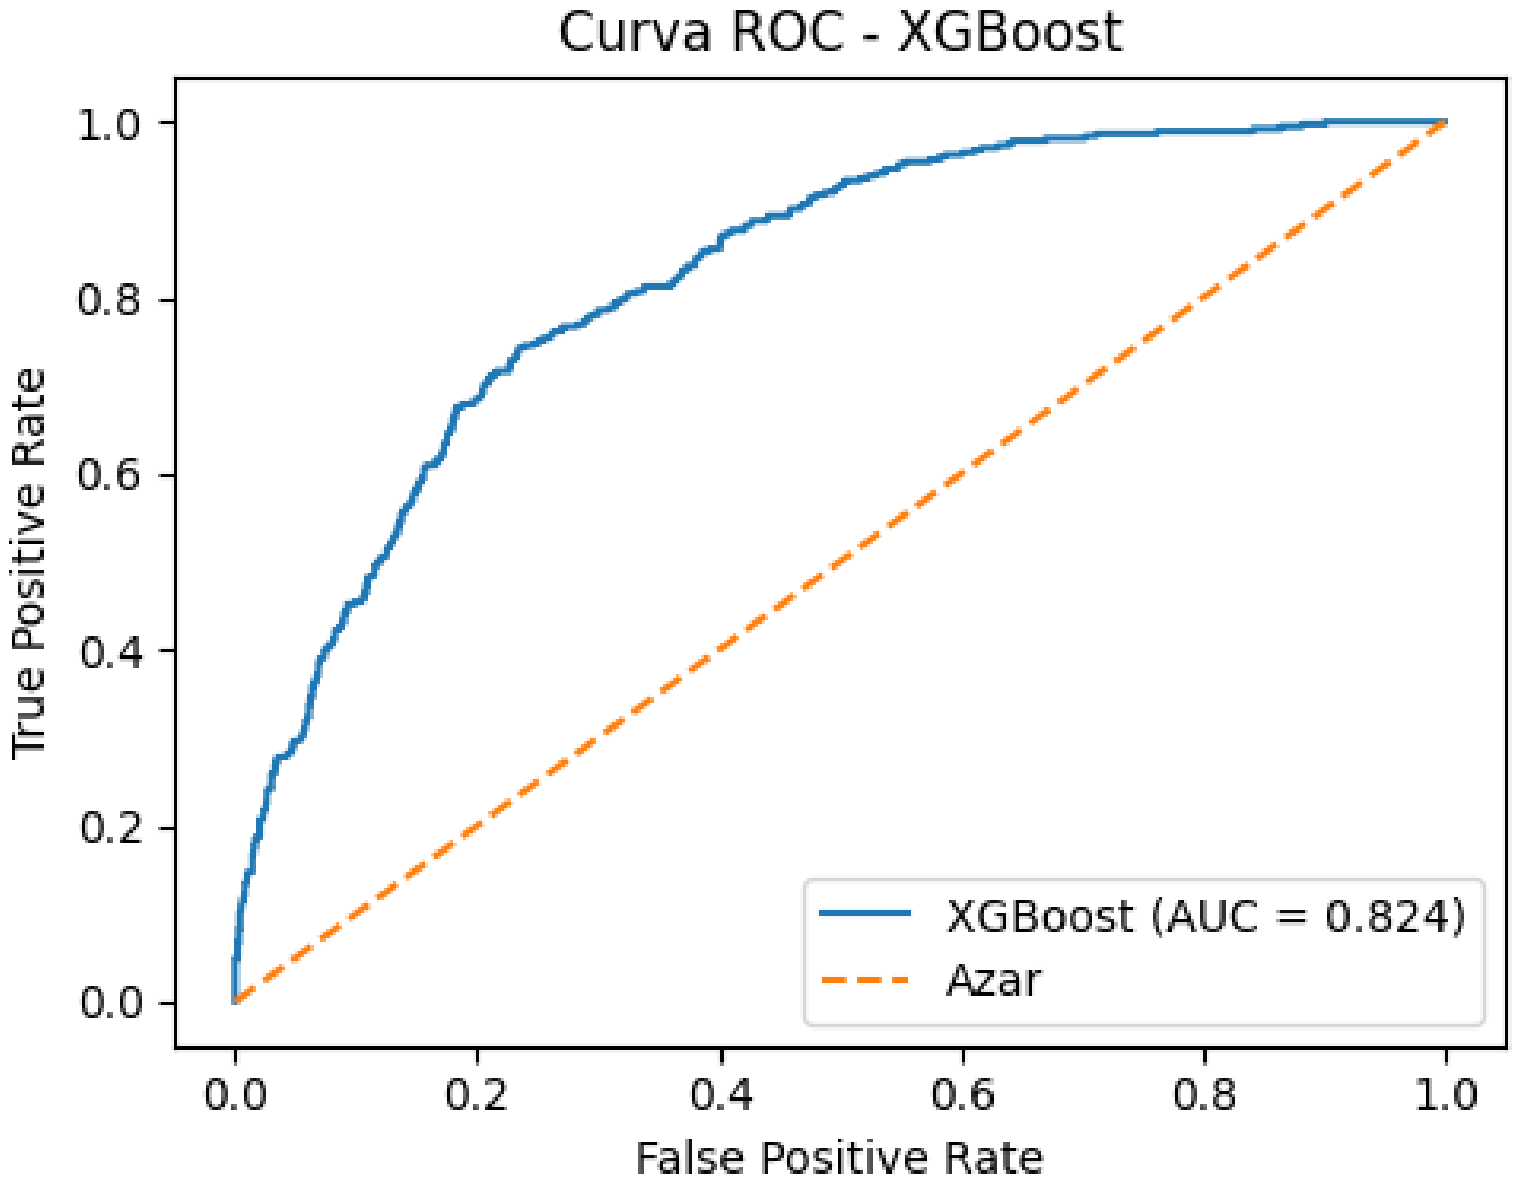

Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

XGBoost

Resultados modelo

- **Accuracy (exactitud):** $\approx 0{,}74$
- **Precision (clase churn):** $\approx 0{,}51$
- **Recall / Sensibilidad (clase churn):** $\approx 0{,}76$
- **F1-score (clase churn):** $\approx 0{,}61$
- **ROC-AUC:** $\approx 0{,}82$

Red neuronal

¿Qué hace?

- Toma todas las variables del cliente como entrada.
- Las pasa por varias capas de neuronas que combinan la información de forma no lineal.
- Aprende automáticamente los pesos para aproximar la probabilidad de **churn**.
- Entrega como salida una probabilidad de que el cliente se vaya de la compañía.

Red neuronal

Características:

- La entropía cruzada es la función de costo más utilizada para entrenar redes neuronales en problemas de clasificación con clases mutuamente excluyentes.

$$L(f(x), y) = \text{CE}(f(x), y) = -\sum_k y_k \log\left(f_k(x)\right)$$

- 4 capas ocultas con arquitectura: $1218 \to 64 \to 32 \to 16$ neuronas.
- Batch Normalization y Dropout para regularización
- Early stopping y reducción de learning rate
- Métricas completas de clasificación

Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Red neuronal

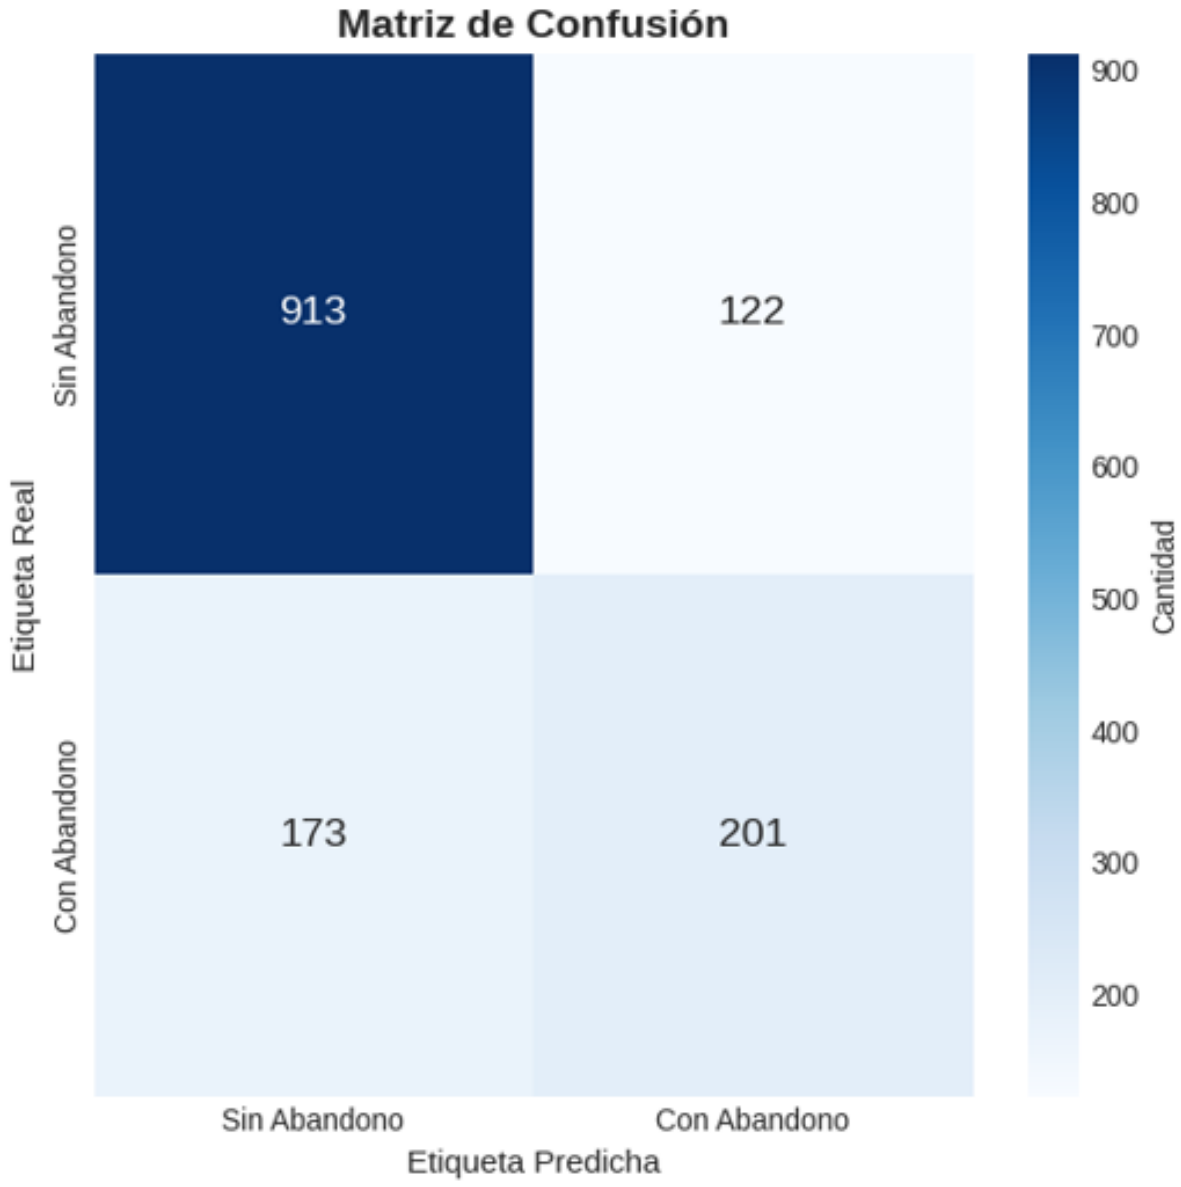

DMAT
Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Red neuronal

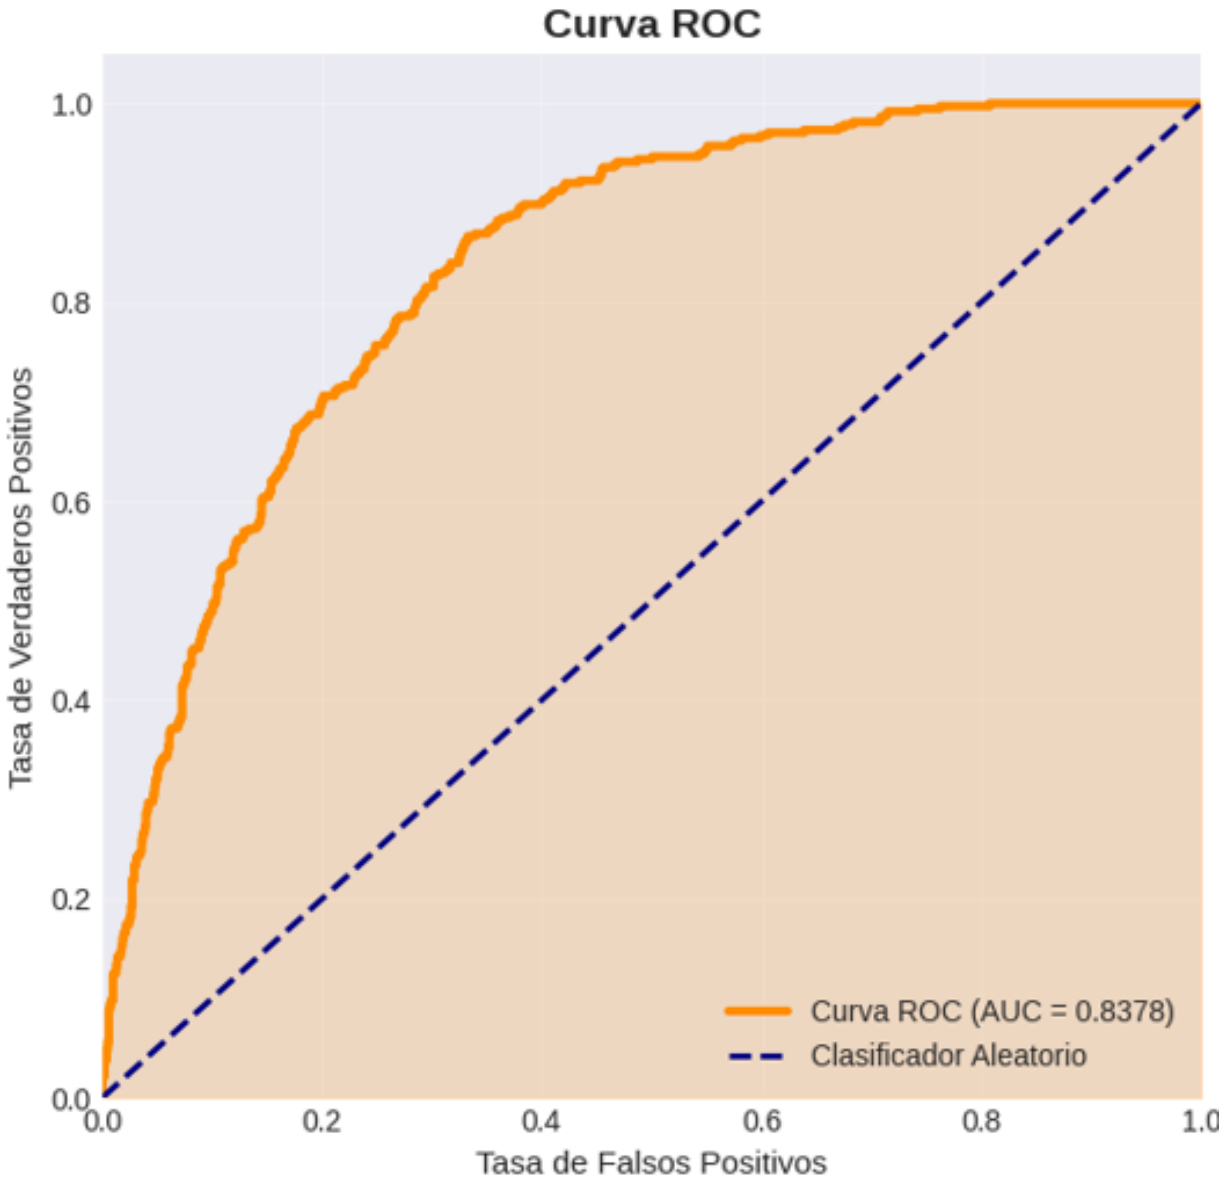

DMAT
Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Red neuronal

Resultados modelo

- **Accuracy (exactitud):** 0.7906 (79.06%)
- **Precision (clase churn):** 0.6223 (62.23%)
- **Recall / Sensibilidad (clase churn):** 0.5374 (53.74%)
- **F1-score (clase churn):** 0.5768 (57.68%)
- **ROC-AUC:** 0.8378 (83.78%)

Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Conclusiones sobre los modelos

- **Regresión logística:** mejor equilibrio global. Mayor accuracy (0.8034) y mejor ROC-AUC (0.8422), con F1 de churn $\approx 0{,}60$. Modelo simple e interpretable.

Conclusiones sobre los modelos

- **Regresión logística:** mejor equilibrio global. Mayor accuracy (0.8034) y mejor ROC-AUC (0.8422), con F1 de churn $\approx 0{,}60$. Modelo simple e interpretable.
- **Random Forest:** accuracy (0.7913) y ROC-AUC (0.8224) algo menores, con recall de churn más bajo (0.49). No mejora a la regresión logística, por lo que queda dominado.

Conclusiones sobre los modelos

- **Regresión logística:** mejor equilibrio global. Mayor accuracy (0.8034) y mejor ROC-AUC (0.8422), con F1 de churn $\approx 0{,}60$. Modelo simple e interpretable.
- **Random Forest:** accuracy (0.7913) y ROC-AUC (0.8224) algo menores, con recall de churn más bajo (0.49). No mejora a la regresión logística, por lo que queda dominado.
- **XGBoost:** menor accuracy ($\approx 0{,}74$) y precisión para churn ($\approx 0{,}51$), pero **mayor recall** ($\approx 0{,}76$) y ROC-AUC $\approx 0{,}82$. Detecta más clientes que se van, a costa de más falsos positivos.

Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Conclusiones sobre los modelos

- **Regresión logística:** mejor equilibrio global. Mayor accuracy (0.8034) y mejor ROC-AUC (0.8422), con F1 de churn $\approx 0{,}60$. Modelo simple e interpretable.
- **Random Forest:** accuracy (0.7913) y ROC-AUC (0.8224) algo menores, con recall de churn más bajo (0.49). No mejora a la regresión logística, por lo que queda dominado.
- **XGBoost:** menor accuracy ($\approx 0{,}74$) y precisión para churn ($\approx 0{,}51$), pero **mayor recall** ($\approx 0{,}76$) y ROC-AUC $\approx 0{,}82$. Detecta más clientes que se van, a costa de más falsos positivos.
- **Red neuronal:** resultados muy cercanos a la regresión logística (accuracy 0.7906, ROC-AUC 0.8378), sin una mejora clara pero con mayor complejidad.

DMAT
Departamento de Matemática
UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

Conclusión

En resumen, si buscamos un modelo equilibrado y fácil de interpretar, elegimos la **regresión logística**; si priorizamos detectar la mayor cantidad posible de clientes en riesgo, el **XGBoost** es el modelo más atractivo.